

意向书 (Expression of Interest)

Blueprint Biosecurity — 征集公告：无差别生物威胁检测 (Pathogen-Agnostic Biothreat Detection)

技术领域： TA1 — 在 MGS 数据中对已知与新颖病原体的计算检测

项目题目： SIEVE-MGS — 面向生产规模宏基因组生物监测的、带召回率保证的蒸馏式 read 级新颖性筛查

项目负责人 (PI)： 彭思华 (Sihua Peng)，博士 —

佐治亚大学公共卫生学院研究科学家；佐治亚州先进计算资源中心 (GACRC) 联署

依托单位： 美国佐治亚大学 (University of Georgia)，佐治亚州雅典市

申请执行期： 12 个月

申请预算 (概算)： \$269,500 (直接费 + 间接费；详见第 5 节)

日期： [填写] | **联系方式：** [填写邮箱 / 电话]

1. 问题陈述

一个实际运行的宏基因组监测项目每周产生约 10^{10} 条 reads。而最擅长识别“从没有人见过的病毒”的那类模型，根本跑不动它们。

这是结构性约束，不是资源抱怨。基因组基础模型确实实质性地提升了新颖病毒的识别能力——基于 DNABERT-2 构建的 ViraLM 是最清楚的例证 [1]——

但它们对每条序列的推理开销在毫秒量级，比汇水区级别的周度运行所能承受的速度慢四到五个数量级。标准应对是“先组装、再对 contig 而非 read 打分”。而它恰恰在早期预警所在的区间失效：相对丰度 10^{-7} 的病原体在一份样本里只贡献个位数的 reads，永远拼不出 contig。组装不是中性的提效步骤，它是一道灵敏度地板，正好铺在我们想捕捉的信号底下。

于是流程被迫在两个都会关键情形上失效的选项之间二选一：快速的、基于参考库的分类器无法给库里没有的东西打分；准确的无参考模型则在规模上负担不起。像 DeepVirFinder [2] 这样的 read 级分类器介于两极之间，但它早于基础模型时代，也未针对“新颖性”（区别于“病毒性”）校准。

SIEVE-MGS

不是在这两难之间折衷，而是把它取消掉，依据的是一个观察：如果把基础模型当作“教师”而不是“预测器”，它的代价就只在训练时付一次，而不在推理时付。我们把基础模型的表征蒸馏进一个紧凑的 read 级筛查器，使其在无需任何参考索引的前提下达到生产吞吐量；并且——因为一个要丢弃 99.99% 数据的滤网，只有在你能界定它丢掉了什么的时候才敢部署——我们为“被丢弃的真阳性 reads 所占比例”附上一个可证明的上界。其成果不替代任何东西：它是一道前置滤网，任何现有项目都可以装在自己已在跑的流程前面。

2. 技术路线

目标一 — 蒸馏出带召回保证的 read 级新颖性模型 (第 1–7 月)

为什么必须是蒸馏，而不是直接训一个小模型。

这是本项目的核心主张，也是唯一一条可被证伪的主张。一个在留出分支 (leave-one-clade-out) 数据上从零训练的紧凑网络，学到的是“它见过的那些分支长什么样”，超出这一经验就会退化。强迫学生去匹配教师模型的表征几何

[6,7]，迁移的是“病毒性”这一抽象结构，而不是对具体分支的记忆。因此训练目标包含两项：留出分支模拟数据上的监督损失，以及针对冻结的教师嵌入的表征匹配损失。第 3 月的消融实验直接检验表征匹配项是否就是跨分支泛化的来源。

如果不是，本项目的前提即为错误，而我们会早到还来得及调整的时候就知道。

请注意学生学的是什么：它从不翻译，也从不看见蛋白。它学的是直接在原始核酸空间里识别出 ESM-2 只有翻译之后才能看到的蛋白层面特征。

教师只用一个蛋白通道，这是一项技术决策。

核酸语言模型在这里不可用，原因有两条且彼此独立：其一，它们的语料恰恰缺少我们需要的东西——Evo 2 出于生物安全刻意剔除了感染真核宿主的病毒，在正是这类序列上困惑度很高 [3]，Nucleotide Transformer 一系则建立在宿主而非病毒基因组之上 [4]；其二，一条 150 bp 的 read 只有 30–40 个 token，而这些模型按千碱基级上下文训练，何况低于 80% ANI，信号大体已离开核酸字母表。蛋白层面没有。因此教师是**单独的 ESM-2 [5]**，作用于六个翻译框并跨框汇合：其 UniRef 语料含病毒蛋白，表征能在早期预警所处的发散区间存活。不含编码内容的 reads 并非盲区：六个框都会被嵌到远离蛋白空间处，这本身即信息。50 aa 片段的嵌入质量作为第 1 月检查项。教师仅离线运行、仅用于训练数据，不属于交付物。

标签来自构造，而不是来自教师。

被留出的分支会从所有参考库、训练集与教师拟合集中整体移除；随后在真实错误谱下从留出基因组模拟 75–300 bp 的 reads 并注入真实污水背景，真值因构造而精确。难度以“到最近保留邻居的 ANI”连续标定，结果按难度分层报告——因为汇总会掩盖 80% 以下同一性那个区间，而真正新颖的病原体恰恰落在那里。

模型有两个输出头，而负类并不干净。 我们分别估计 $p(\text{感染脊椎动物})$ 与 $p(\text{位于已知病毒空间之外})$ ——

噬菌体在污水病毒组中占绝对多数，属背景而非信号——两者同时高的 reads 才保留。真实背景并非干净的负样本集：其中既有**已知病毒**（可比对参考库重标），也有**未知病毒**（无法识别，而它们恰恰是我们的目标）。因此我们不把背景当作负类，而是在**正样本—未标注（PU）框架 [9]** 下训练，并估计背景中残余的正类比例，使报告的假阳性率不被正确检出抬高。学生模型是反向互补等变的膨胀卷积网络 [8]， $\leq 5M$ 参数、INT8 量化，同时处理双链与 DNA/RNA，长读分块处理。

保证才是它可部署的原因。 借助 conformal risk control [10]，我们选取保留阈值 λ ，使得真正新颖的 reads 落入**被丢弃集合**的期望比例不超过 ϵ ，置信度为 $1-\delta$ 。目标一的核心交付物不是某一个工作点，而是完整的**(ϵ , 压缩比) 曲线**：你说出你能容忍多大的漏检率，我们说出数据能消失几个数量级。

我们同样会写出这个保证在哪里变弱。Conformal risk control 依赖可交换性，而不同汇水区、季节、文库化学之间并不可交换。因此我们按站点做滚动校准，并把“该界在刻意分布漂移下退化多少”作为具名交付物报告，而非塞进附录。

目标二 — 生产特性刻画与“即插即用”部署（第 4–12 月）

决定性的实验可以用一句话概括：**只喂给下游流程 0.01% 的 reads，它还能不能找到同样的东西？** 我们把 SIEVE-MGS 装在 nf-core/mag、mgs-workflow、Kraken2/Bracken 与 geNomad 前面，比较“全量输入”与“筛后输入”在回收类群、contig 与标记候选上的一致性，同时给出端到端的墙钟时间与美元成本。“**同样的答案，千分之一的算力**”这句话，决定了 CDC Biothreat Radar、NWSS 或 mSCAPE 这类项目是否真的装得上去——因此它是被测量出来的，不是被断言的。

另有三项刻画并行进行。

吞吐与成本。 每 GPU 与每 CPU 核的 reads/秒、商用云上每十亿 reads 的成本、常驻内存，以及无需加载索引的流式模式。许多州公共卫生实验室没有 GPU，因此纯 CPU 路径是刚需而非附赠。目标是在 A100 级 GPU 上达到 $\geq 5 \times 10^6$ reads/s——百亿 reads 的周度运行约五个 GPU-小时——但**实测数字本身就是主要交付物**，无论结果如何都会公布。

真实背景下的保留率。 在模拟数据上压缩 $10^4\times$ 什么也证明不了。我们在 CASPER (PRJNA1247874)、NWSS (PRJNA747181)、Tisza 2023 (PRJNA966185)、Wolfe 2026 (PRJNA1438722) 与 Zephyr/Broad 鼻拭子 (PRJNA1052714) 上实测保留率，最后一项兼测跨样本类型迁移。如果真实污水只压得动 $100\times$ ，我们就报 $100\times$ ——因为 $100\times$ 在运营上依然是决定性的。

历史突发事件上的召回。 针对 2022 年 mpox 与 2024 年 H5N1 入污水，我们只问本项目该负责的那个窄问题：在相关 reads 确实存在的最早时间点上，**筛查器把它们保留下来了吗？** 是否告警、何时告警是另一个问题，本提案不声称回答。

3. 交付物、开放获取与执行速度

sieve 自第 3 月起以 MIT/Apache-2.0 许可在 GitHub 公开，全程开放开发而非结束时一次性倾倒：PyTorch 训练代码、ONNX/TensorRT 部署、纯 CPU 回退，以及 nf-core 风格的 Nextflow 模块——已在跑 nf-core/mag 的项目只需加一步即可接入。权重、校准工件与基准数据发布至 Hugging Face 与 Zenodo（附持久 DOI）。预计两篇论文，均在投稿时同步预印。

我们**刻意不另建基准数据集**：已有或将有的公开基准都会在其上评测，并把留一分支划分回馈社区。本项目的贡献是模型、保证与实测运行成本。

关于执行速度：不需湿实验、新采样或新硬件；数据均已公开并下载完毕，分析第一周即可开始。两个主要检查点都刻意设计成“早失败而非晚失败”。

4. 团队与能力

彭思华博士 — 项目负责人。佐治亚大学公共卫生学院研究科学家；40 余篇同行评审论文（h 指数 24），横跨计算生物学、生物统计学与机器学习。**本项目里深度学习那一半是已被证实的能力，而非自述：**PI 长期开发并公开发布微调的蛋白与生物语言模型（huggingface.co/sihuaapeng），数个为 3B 量级——**正是目标一教师所依托的同一模型家族：**这也是我们能为 RFP 开放性评分项提供的最直接证据：**sieve** 的权重与校准工件将以同样方式发布在同一平台。PI 同时在 Illumina、PacBio HiFi 与 Nanopore 三平台开展生产级宏基因组工作，经 GACRC 的 SLURM 集群规模化运行。这一组合很少见：蛋白语言模型工程、无分布假设的不确定性量化，以及对宏基因组流程真实成本的一手经验。目标一里的那个保证不是装饰——它是公共卫生项目愿意丢掉 99.99% 数据的**唯一理由**，而把它陈述正确首先是统计学问题，其次才是机器学习问题。

我们欢迎 **Blueprint** 引荐运营方伙伴（NWSS 水厂、佐治亚州公共卫生部、CASPER、Zephyr）开展部署测试，也乐于与互补的 TA1/TA2 提案组队。

*同期提交声明：*本组另行提交一份 TA3 意向书（DPD，序贯检测统计学与预算—预警时长建模），由 Justin Bahl 教授任 PI。两者互补而独立：**SIEVE-MGS** 决定哪些 reads 值得留下，DPD 决定一条轨迹何时值得告警、要花多少钱。各自自洽、独立立项与编列预算、由不同负责人牵头，任何一方都不以另一方获资助为前提。

5. 预算概算（12 个月）

类别	金额
PI 工时（25% FTE）	\$40,000
博士后研究员 / 机器学习科学家（100% FTE）	\$82,000
研究生助研（50% FTE，含学费）	\$46,000
员工福利（Fringe）	\$37,000
GPU 计算：教师推理、蒸馏训练与吞吐基准	\$30,000
发表、传播与差旅	\$10,000
直接费用合计	\$245,000
间接费用（直接费 10%，按 Blueprint 政策）	\$24,500
申请总额	\$269,500

计算费确有必要：生成教师嵌入与跨硬件刻画吞吐都是 GPU 密集型的，单一设备上测出的数字毫无价值。GACRC 免费提供集群计算、存储与容器基础设施，因此这一行仅覆盖云端弹性算力与归档托管。间接费用按 Blueprint 公布的 10% 上限编列；佐治亚大学协商 F&A 费率高于此值，机构豁免申请正通过科研办公室着手办理，而非拖到全额提案阶段。项目按模块设计：**若 Blueprint 倾向更紧凑的范围，仅目标一即构成一个自洽的独立项目，约 \$175,000。**

6. 风险与应对

蒸馏可能无法跨分支迁移。中心假设，最先检验：第 3 月的消融对照“去掉表征匹配项、尺寸相同”的模型，按 ANI 分层。若该项毫无贡献，退路是放大学生模型——仍比教师快两个数量级——而这一否定结果本身即可发表。

真实背景的压缩比可能远低于模拟数据。在第 2 月而非第 10 月测量。交付物是 (ϵ , 压缩比) 曲线，不是营销数字。

可交换性失效会削弱 conformal 界，且足够发散的病原体可能逃过任何学习到的表征。

前者以逐站点滚动校准应对，退化幅度由跨站点、跨季节、跨平台的漂移压力测试量化；后者正是筛查器设为高召回、低精度的原因——我们界定的是被丢弃的部分而非被保留的部分，控假阳性是下游的职责。

7. 参考文献

1. Peng C, Shang J, Guan J, Wang D, Sun Y. ViraLM: empowering virus discovery through the genome foundation model. *Bioinformatics* 2024;40(12):btae704.
2. Ren J, Song K, Deng C, Ahlgren NA, Fuhrman JA, Li Y, Xie X, Poplin R, Sun F. Identifying viruses from metagenomic data using deep learning. *Quantitative Biology* 2020;8(1):64–77.
3. Brixi G, Durrant MG, Ku J, et al. Genome modelling and design across all domains of life with Evo 2. *Nature* 2026. (预印本: *bioRxiv* 2025.02.18.638918)
4. Dalla-Torre H, Gonzalez L, Mendoza-Revilla J, et al. Nucleotide Transformer: building and evaluating robust foundation models for human genomics. *Nature Methods* 2025;22(2):287–297.
5. Lin Z, Akin H, Rao R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science* 2023;379(6637):1123–1130.
6. Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network. *arXiv:1503.02531*, 2015.
7. Romero A, Ballas N, Kahou SE, Chassang A, Gatta C, Bengio Y. FitNets: hints for thin deep nets. *Proceedings of ICLR* 2015.
8. Shrikumar A, Greenside P, Kundaje A. Reverse-complement parameter sharing improves deep learning models for genomics. *bioRxiv* 103663, 2017.
9. Kiryo R, Niu G, du Plessis MC, Sugiyama M. Positive-unlabeled learning with non-negative risk estimator. *Advances in Neural Information Processing Systems* 2017;30.
10. Angelopoulos AN, Bates S, Fisch A, Lei L, Schuster T. Conformal risk control. *Proceedings of ICLR* 2024.
11. Saito T, Rehmsmeier M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE* 2015;10(3):e0118432.

根据 RFP 规定，参考文献不计入页数限制。
